



인구감소 R&D 플랫폼

데이터 분석 보고서

Ver. 1.0

작성일	2026-09-16
작성자	[확인 필요]
대상 코드베이스	F:/rnd_github/pcnrnd/Population_decline @ 449f6aa

문서 정보

버전	일자	작성/변경자	변경 내용
1.0	2026-09-16	[확인 필요]	최초 작성

목 차

문서 정보.....	2
1. 요약과 분석 범위	5
1.1 한 눈에	5
1.2 분석 범위.....	5
2. 원천 데이터와 결합 구조	7
2.1 데이터셋 사전	7
2.2 원천 · 전처리 · 파생 구분	8
2.3 단위	8
2.4 실제 테스트 사용 여부	8
3. 데이터 품질.....	9
3.1 누락 율과 지역	9
3.2 중복 키	10
3.3 조인 카디널리티와 행 증식	10
3.4 결측 vs 진짜 0	10
3.5 단위 · 코드 변화	11
3.6 강원 GWTO 의 유효 구간 이질성	11
3.7 지역 편중.....	12
4. 기간 · 지역 · 지표 탐색 분석	13

4.1 남원 방문객 (월 × 23 동)	13
4.2 남원 소비 (월 × 23 동).....	13
4.3 강원 GWTO (월 × 18 시군구)	14
4.4 서울 노원 축제 (일 × 단일 지점)	14
5. 테스트 데이터 구성과 누수 점검.....	15
5.1 구성	15
5.2 분할	15
5.3 누수 점검 결과	15
5.4 홀드아웃에 대한 사실 정정	16
6. 확인된 모델 결과와 데이터 한계의 연결.....	16
6.1 확정된 결과	16
6.2 데이터 한계와의 연결	17
6.3 남은 한계.....	18
7. 통합 활용 가능성과 개선안	18
7.1 결합 가능성 판정.....	18
7.2 데이터셋별 활용 판정	19
7.3 개선안.....	19
8. 부록 — 재현 절차	20
8.1 그림 재생성	20
8.2 분석 재생성	20

8.3 모델 결과 출처	21
8.4 미확정 항목	21

1. 요약과 분석 범위

1.1 한 눈에

인구감소 플랫폼이 보유한 전처리 데이터 41 개 CSV · 281,536 행을 데이터셋 단위로 점검했다. 결론은 네 가지다.

1. 네 데이터셋은 서로 다른 지역 · 입도 · 관측 단위를 가진다. 남원(전북) 월×행정동, 강원 월×시군구, 서울 노원 일×단일 지점이다. 하나의 표로 합칠 수 있는 조합은 남원 2 종뿐이다.
2. 품질은 데이터셋마다 크게 다르다. 남원 KT 방문객은 58 개월×23 동 격자가 결손 없이 완전하다. 남원 BC 카드는 2020~2021 년 24 개월이 원천 추출본에 없다. 강원 GWTO 는 표마다 유효 시작월이 9 종으로 갈린다.
3. 적재 가능 범위와 분석 도달 범위가 다르다. 적재 도구는 4 개 패밀리를 모두 지원하지만, 분석 · 모델 API 가 읽을 수 있도록 허용된 테이블은 남원 3 개뿐이다. 강원 · 노원 데이터는 현재 모델 경로에 도달하지 못한다.
4. 2026-09-16 모델 검증은 남원 3 개 테이블만 다뤘다. 전체 데이터가 모델로 검증되었다는 뜻이 아니다.

1.2 분석 범위

포함: `platform/data/real`(원천 8 건)과 `platform/data/prepared`(41 CSV) 전체.

제외와 사유:

경로	파일	제외 사유
----	----	-------

경로	파일	제외 사유
./data	1	gitignore 된 레거시 폴더, 플랫폼 데이터 계약 밖
./archive/data	12	초기 탐색 아카이브, gitignore
./data_version	15	DVC 추적 내용이 리츠(REIT) 공시 PDF 로 인구감소와 무관

로컬 미확보·외부 연결만 있는 자료는 없다. 분석에 쓴 모든 파일은 로컬에 존재하며 해시를 고정했다. 다른 프로젝트의
원천으로 확장하거나 새로 데이터를 수집하지 않았다.

그림 1. 원천에서 모델까지의 데이터 계보와 도달 범위




그림 1. 원천에서 모델까지의 데이터 계보와 도달 범위

2. 원천 데이터와 결합 구조

2.1 데이터셋 사전

데이터셋	지역	입도	관측 단위	기간	표	행
namwon_kt_visitors	전북 남원시 23 개 행정동	월	(base_ym, dong_code)	2019- 01~2023-10	2	22,676
namwon_bccard_consumption	전북 남원시 23 개 행정동	월	(base_ym, 고객유형, dong_name, 업종, 성별, 연령, 요일) 7 부 키	2019- 01~2023-12	2	212,368
gwto_kt_tourism_indicators	강원도 18 개 시군구	월(1 개 표는 일)	표마다 다름 — 도·시군구·관광지점	2020- 01~2025-12	26	21,887
nowon_kt_festival	서울 노원구 단일 축제 지점	일	(date, spot_name)	2025-08- 14~2025- 09-15	11	24,605

2.2 원천 · 전처리 · 파생 구분

- 원천(8 건): `namwon_kt_visitors_20231130.xlsx`, `namwon_bccard_consumption_240130.xlsx`,
`gwto_kt_tourism_indicators_202512.xlsx`, `nowon_kt_festival_20250919.xlsx`,
`admin_boundary_kostat2013.geojson`, 남원·신안 복지시설 CSV 2 건, `README.md`.
- 전처리(41 CSV): `MANIFEST.csv` 가 표마다 `rows_in` / `rows_out` / `rows_dropped` / `transforms` /
`key_columns` 를 기록한다. 남원 2 종은 `column_rename`; `type_fix` 만 적용되어 값 변경이 없다.
- 파생: 분석·모델이 쓰는 스냅샷은 전처리 CSV 를 PG 에 적재한 뒤 (`base_ym`, `dong_code`) 단위로 집계해 만든다.
소비는 `sum(sales_est_krw)` 집계가 필요하다.
- 중복 사본: `platform/data/prepared` 내에 동일 내용의 중복 사본은 없다. 원천 `xlsx` 와 전처리 CSV 는 별개
계층이며 중복이 아니다.

2.3 단위

방문객·축제 계열은 명, 소비는 원(추정 카드 매출), GWTO 는 표에 따라 명·원·비율·순위가 섞인다. 단위가 다른 값을
직접 비교하지 않는다.

2.4 실제 테스트 사용 여부

데이터셋	적재 도구 지원	분석 API 도달	2026-09-16 검증에서 실제 적재
<code>namwon_kt_visitors</code>	O	O (2 개 표)	O
<code>namwon_bccard_consumption</code>	O	O (1 개 표)	O
<code>gwto_kt_tourism_indicators</code>	O	X	X
<code>nowon_kt_festival</code>	O	X	X

도달 허용 목록은 pg_reader.ALLOWED_TABLES 3 개(ext_kt_namwon_monthly_dong_visitors, ext_bccard_dong_industry_sales, ext_kt_namwon_visitors_by_sex_age)로 고정되어 있다.

3. 데이터 품질

3.1 누락 월과 지역

데이터셋	기대 월	실제 월	누락
남원 KT 방문객	58	58	0
남원 BC 카드 소비	60	36	24 (2020-01~2021-12)
강원 GWTO	표마다 상이	표마다 상이	아래 3.6
서울 노원 축제	33 일	33 일	0

남원 KT 는 58 개월 $\times$ 23 동 = 1,334 행이 격자를 정확히 채운다(결손 0).

남원 BC 카드의 24 개월 공백은 원천 추출본 자체에 2020·2021 년 행이 없기 때문이다(연도별 행수: 2019 년 67,879 / 2022 년 74,045 / 2023 년 70,418). 전처리 결함이 아니므로 보간·제로채움하지 않는다.




그림 2. 데이터셋별 관측 기간과 관측 단위 (빗금 = 원천 공백 2020-2021)

3.2 중복 키

- 남원 KT (`base_ym`, `dong_code`) 중복 0
- 남원 BC 카드 7 부 키 중복 0
- 강원 GWTO 내비 순위표 2 건에 중복 존재: `23_s4_1_navi_top500_prev_month.csv` 2 건,
`24_s4_2_navi_top500_prev_year.csv` 3 건. 순위 표 특성상 동명 지점이 복수 행으로 들어온 것으로 보이며, 이 두 표를 키 기준으로 조인할 때 주의가 필요하다.

3.3 조인 카디널리티와 행 증식

남원 KT 는 (월, 동)당 1 행이다. 남원 BC 카드는 같은 키에 대해 최소 3 행 · 중앙값 216 행 · 최대 693 행을 갖는다(고객유형×업종×성별×연령×요일 차원).

따라서 두 표를 원시 상태로 조인하면 최대 693 배 행 증식이 발생한다. 반드시 BC 카드를 (`base_ym`, `dong`) 단위로 먼저 집계해야 하며, 현재 스냅샷 생성 로직이 이 집계를 수행한다.

3.4 결측 vs 진짜 0

두 개념을 구분해야 하며, 이 데이터에서는 서로 다른 형태로 나타난다.

- 진짜 0: 남원 KT `foreign_visitors` 에 169 건의 0 이 있다. 빈 셀이 아니라 관측된 0 이며, 외국인 방문이 없었던 (월, 동)을 뜻한다. 결측 처리 대상이 아니다.
- 비어 있음: 남원 KT · BC 카드 모두 숫자 컬럼에 비숫자 · 빈 셀이 0 건이다. 음수도 0 건이다.
- 행 자체의 부재: 결측은 값이 아니라 행의 부재로 나타난다. 집계 행이 없는 (월, 동)은 스냅샷에 들어가지 않는다.

여기서 모델 피처의 전년동월 결측 표시(`has_yoy`)와 소비 2020~2021 원천 공백은 서로 다른 문제다.

구분	소비 2020~2021 공백	전년동월 결측 flag

구분	소비 2020~2021 공백	전년동월 결측 flag
정체	원천 추출분에 24 개월의 행이 없음	특정 표본에서 t-12 관측을 참조할 수 없음
원인	데이터 제공 범위	계열 시작 직후 또는 위 공백을 가로지르는 구간
처리	보간하지 않음. 행을 만들지 않는다	has_yoy=0 으로 표시하고 y_yoy 를 같은 행 y_lag1 로 대체
근거	원천 연도별 행수 확인	대체값은 t-1 값이므로 미래 정보가 들어가지 않음

전자는 데이터에 없는 것을 만들지 않는다는 원칙이고, 후자는 있는 정보로 표시하고 대체한다는 처리다. 둘을 같은 문제로 묶지 않는다.

3.5 단위·코드 변화

- 남원 KT 는 행정동 코드(**dong_code**, 8 자리)를, BC 카드는 행정동 이름(**dong_name**)을 쓴다. 대응표 **namwon_dong_map.json** 이 23 개를 모두 매핑하며 미매핑 0 건이다.
- 방문객 값이 소수점을 포함한다(예: 최소 4,637.5). 추정·보정된 값이므로 정수 카운트로 취급하지 않는다.
- 소비 금액 범위는 44 원~361,841,766 원으로 5 자리 이상 폭이 넓다. 로그·정규화 없이 단순 합산 비교를 하면 대형 동이 지표를 지배한다(3.7 참조).

3.6 강원 GWTO 의 유효 구간 이질성

26 개 표의 유효 시작월이 9 종(202001, 202003, 202102, 202301, 202310, 202401, 202412, 202502, 202511)으로 갈린다. 종료월은 202412 또는 202512 다.

즉 표마다 분모가 다르다. 같은 축에 올려 비교하려면 구간을 다시 맞춰 명시해야 한다. 또 19_s3_4_city_hour.csv 와 21_s3_6_city_region.csv 2 건에는 기간 컬럼이 없어 시계열 축에 올릴 수 없다.




그림 3. 강원 GWTO 지표 테이블별 유효 구간 — 시작월이 제각각이라 분모가 다르다

3.7 지역 편중

남원 23 개 행정동은 고르게 분포하지 않는다.

- 방문객: 상위 1 개 동이 12.6%, 상위 5 개가 48.0%, 하위 5 개는 합쳐서 5.2%
- 소비: 상위 1 개 동(도통동)이 20.8%, 상위 5 개가 65.8%




그림 4. 남원 23 개 행정동의 점유율 편중 — 각 지표를 자기 합계로 정규화한 값 (단위가 달라 절대량 비교 아님)

이 편중은 6 장에서 모델 오차 구조와 연결된다.

4. 기간·지역·지표 탐색 분석

아래 각 절은 해당 데이터셋 안에서만 읽는다. 한 데이터셋에서 얻은 결론을 다른 지역·다른 입도의 데이터셋으로 옮기지 않는다.

4.1 남원 방문객 (월 × 23 동)

23 개 동 합계 기준 월별 외지인 방문객은 뚜렷한 연주기를 보이며, 2020 년 전후로 수준이 낮아졌다가 회복하는 형태다.

표본 수 1,334 행, 분모는 58 개월 × 23 동이다.




그림 5. 남원시 월별 외지인 방문객 합계 (23 개 행정동 합, 2019-01~2023-10)

동별 평균 규모는 4,637.5 명에서 274,683.5 명까지 분포해 약 59 배 차이가 난다.

4.2 남원 소비 (월 × 23 동)

월 합계 추정 매출은 2019 년 약 208~280 억 원 구간에서 움직이고, 24 개월 공백 뒤 2022~2023 년에는 169~294 억 원 구간이다. 공백을 사이에 둔 두 구간을 연속 추세로 읽지 않는다.




그림 6. 남원시 월별 BC 카드 추정 매출 합계 (2019-01~2023-12, 2020~2021 원천 부재)

4.3 강원 GWTO (월 × 18 시군구)

26 개 표가 방문객·소비·숙박·거주지·내비 검색 등 서로 다른 지표군을 담는다. 유효 구간이 표마다 달라(3.6) 전체를 한 축에 올린 종합 추세는 만들지 않았다. 남원에서 관찰된 계절성·편종을 강원에 적용하지 않는다.

4.4 서울 노원 축제 (일 × 단일 지점)

2025-08-14~2025-09-15 의 33 일 구간, 단일 축제 지점이다. 일별 방문객과 시간대·성연령·국적·체류시간 표가 함께 있다.




그림 7. 서울 노원 축제 일별 방문객 (단일 지점)

한 달 남짓한 단일 지점 자료이므로 월 단위 패널이나 지역 비교에 쓸 수 없다.

5. 테스트 데이터 구성과 누수 점검

5.1 구성

현재 모델이 쓰는 테스트 데이터는 남원 2 중에서 만든 (**base_ym**, **dong_code**) 패넬이다.

타깃	원시행	피쳐행	lag 연속성 제외	최신 학습/평가	유효 평가창
nonlocal_visitors	1,334	1,265	69	1,196 / 69	52 (2019-07~2023-10)
observed_sales_krw	828	690	138	621 / 69	25 (2019-07~2023-12)

피쳐는 30 개(**y_lag1~3**, **y_yoy**, **has_yoy**, **month_sin**, **month_cos** + 행정동 one-hot 23)다.

적재 원천 행수와 분석 관측행을 혼동하지 않는다. 2026-09-16 검증의 PG 적재 235,018 행은 원천 3 개 테이블의 행수이고, 위 828 · 1,334 행은 집계 후 관측행이다.

5.2 분할

학습 **base_ym** ≤ T-3, 평가 {T-2, T-1, T}(69 행 = 23 동 × 3 개월), 예측 대상 T+1. 예측 시점(T)을 굴리며 반복한다.

5.3 누수 점검 결과

점검	결과
학습 최대월 ≤ T-3	PASS
평가 최소월 > 학습 최대월	PASS
train/eval 월·행키 교집합	0 (PASS)

점검	결과
학습 집합에 미래월 포함	없음 (PASS)
표준화·동별 통계 산출 범위	학습행만 사용 (PASS)
변이 선택이 평가창을 관측	안쪽 구간만 사용 (PASS)

표본 t 의 모든 피쳐는 $\text{base_ym} < t$ 관측만 쓴다. 전년동월 대체값도 같은 행의 y_lag1 이라 미래 정보가 아니다.

5.4 홀드아웃에 대한 사실 정정

유효 평가창은 방문객 52 개·소비 25 개이며, 이 중 방문객 18 개·소비 6 개 구간은 변이 탐색에서 한 번도 채점되지 않았다. 그러나 이 미관측 구간은 전부 선택집합보다 시간상 앞선다. 이를 홀드아웃으로 잠그면 미래로 고르고 과거에서 시험하는 형태가 되어 시계열 분할 원칙에 어긋난다.

따라서 유효한 전방 홀드아웃은 현재 데이터에서 만들 수 없다. 이미 관측한 말기 구간을 미사용 홀드아웃으로 재분류하지 않는다. 대신 안쪽 구간으로만 변이를 고르고 바깥 구간을 한 번 채점하는 중첩 시간 검증을 썼다.

6. 확인된 모델 결과와 데이터 한계의 연결

이 장은 남원 2 개 모델에 한정된다. 전체 데이터가 모델 검증을 통과했다는 의미가 아니다. 아래 수치는 2026-09-16 에 고정된 기존 증거이며, 이 보고서를 위해 재학습하지 않았다.

6.1 확정된 결과

모델	최신 전체구간 판정	MAE / 기준선
namwon-observed-sales-next-month	승급	102,928,071.82 / 105,160,382.54 (비 0.9788)

모델	최신 전체구간 판정	MAE / 기준선
namwon-nonlocal-visitors-next-month	미달, 정상 거부(HTTP 400)	7,675.788289 / 6,921.123188 (비 1.1090)

기준선은 y_{yoy} (없으면 y_{lag1})를 쓰는 동별 단순 예측이고, 승급 조건은 후보 MAE < 기준선 MAE 다. 이 조건은 이번 작업에서 바꾸지 않았다.




그림 8. 구간별 MAE 비 — 확정된 기준 증거 재사용 (재학습 없음)

6.2 데이터 한계와의 연결

3장에서 확인한 두 가지 데이터 특성이 모델 오차 구조와 직접 연결된다.

(가) 소비의 24 개월 공백 → 전년동월 참조 불가 비율. 소비 학습행 621 개 중 414 개(66.7%)가

$has_yoy=0$ 이다(방문객은 1,196 개 중 207 개, 17.3%). 과거에는 이 경우 y_{yoy} 에 리터럴 0 을 넣었는데, 원칙도가 약 10°인 열에 2/3 가 0 스파이크로 들어가 공유 기울기를 왜곡했다. 같은 행 y_{lag1} 로 대체하자 구간별 통과가 10/25 → 13/25 로 올랐다.

(나) 지역 편중 → 소수 동이 오차를 지배. 3.7에서 본 편중 때문에, 23 개 동에 하나의 기울기를 공유하는 선형

모델에서는 대형 동의 잔차가 비례해 커진다. 개선 전 실패 구간에서 방문객 45190460 한 동이 전체 MAE 격차를 혼자 초과했고, 소비는 도통동(45190370)이 격차의 약 절반을 차지했다.

이 진단에 따라 승급 지표(MAE, 조건부 중앙값)와 학습 목적(제곱오차, 조건부 평균)의 불일치를 맞추자 구간별 통과가 소비 10/25 → 18/25, 방문객 21/52 → 30/52 로 올랐다. 안쪽 구간만으로 변이를 고른 중첩 검증에서는 소비 10/12, 방문객 7/12 였다.

주의: 위 수치는 관측된 연관과 확인된 처리 효과다. "공백이 성능 저하의 원인이다"처럼 단일 원인으로 단정하지 않는다.

6.3 남은 한계

1. 변이 후보 목록 자체가 사전 탐색 이후에 설계되어, 중첩 검증으로도 제거되지 않는 편향이 남는다.
2. 방문객 모델은 개선되었으나 중첩 검증 평균 비가 1.0393 으로 여전히 1 을 넘어 안정적 통과가 아니다. 현재 거부 상태가 정상이다.
3. 강원·노원 데이터는 모델 경로에 도달하지 않아 어떤 모델 판정도 받지 않았다.

7. 통합 활용 가능성과 개선안

7.1 결합 가능성 판정

조합	결합	사유
남원 KT × 남원 BC 카드	가능	지역 체계·입도·키 호환. BC 를 (월, 동)으로 선집계 필수(미집계 시 최대 693 배 증식). 겹치는 월 34 개
남원 × 강원 GWTO	불가	지역 자체가 다름(전북 남원 vs 강원 18 시군구). 공통 지역 키 없음
남원 × 서울 노원	불가	지역·입도 모두 다름(월 패널 vs 일 단위 단일 지점)
강원 × 서울 노원	불가	지역·입도 모두 다름

남원 2 종을 결합하더라도 한쪽은 방문객 수, 다른 쪽은 추정 매출로 측정 대상이 다르다. 동반 움직임 기술까지는 가능하나 인과 주장 근거로 쓰지 않는다.

7.2 데이터셋별 활용 판정

데이터셋	판정	근거
namwon_kt_visitors	학습 + 검증	58 개월×23 동 격자 완전, 검증된 모델의 타깃
namwon_bccard_consumption	학습 + 검증 (공백 명시)	집계 후 월×동 패널. 24 개월 공백으로 가용 학습월이 60 개월 중 36 개월
gwto_kt_tourism_indicators	참고용	지역이 다르고 관측 단위가 혼재. 방법 비교 참고는 가능하나 남원 모델의 학습 데이터가 아님
nowon_kt_festival	사용 곤란	단일 지점 33 일. 패널 구조 없음, 남원 월 단위 타깃과 겹침 없음

7.3 개선안

1. 소비 원천 2020~2021 확보 검토. 가장 큰 제약이며, 확보되면 **has_yoy=0** 비율 66.7%가 크게 낮아진다. 보간이 아니라 원천 확보가 유일한 정공법이다. *(범위 밖 판단 — 사용자 결정 사항)*
2. 방문객 모델 후속 개선. 지역 편중을 직접 다루는 구조를 더 탐색한다. 규모 기반 2·3 군 부분공유는 이번에 기각되었으므로 다른 축이 필요하다.
3. 강원·노원 데이터의 위치 재정의. 현재 적재는 되지만 분석에 도달하지 못한다. 참고용으로 남길지 도달 허용 목록을 넓힐지 결정이 필요하다.

4. GWTO 유효 구간 메타데이터화. 표별 시작월이 9 종이라 분석 때마다 재확인 필요하다. 구간 메타를 스키마에 고정하면 반복 비용이 준다.

8. 부록 — 재현 절차

8.1 그림 재생성

```
Set-Location F:/rnd_github/pcnrnd/Population_decline

$A = "docs/reports/2026-09-16-인구감소-데이터분석보고서-자료"

python -X utf8 "$A/make_charts.py" "$A"      # 차트-01 ~ 차트-07 (PNG + CSV)

python -X utf8 "C:/Users/PCN/.claude/skills/tech-doc/scripts/mermaid_to_pptx.py" `
"$A/그림-01.mmd" "$A/그림-01.pptx" "그림 1. 원천에서 모델까지의 데이터 계보와 도달 범위"

# 그림-01.pptx 1 번 슬라이드를 1600x900 PNG 로 내보낸다
```

각 차트는 그린 값을 그대로 담은 차트-NN.csv 를 함께 만든다. 그림 대장은 figures.json 에 있다.

8.2 분석 재생성

산출물	스크립트	결과
전체 인벤토리	inventory.py	stage6-full-data/inventory.json
데이터셋별 품질·탐색	quality.py	stage6-full-data/quality.json
결합 가능성	integration.py	stage6-full-data/integration.json

증거 루트: F:/etc/review-system/artifacts/active/operations/20260916-population-completion/

8.3 모델 결과 출처

6 장 수치는 아래 고정 증거에서 가져왔으며 이 보고서를 위해 재학습하지 않았다.

- `stage4-model/grid.json` — 변이 × 구간 전체 격자
- `stage4-model/nested-validation.json` — 중첩 시간 검증
- `stage5-integration/machine-evidence/verify-result.json` — 격리 PostgreSQL 실검증 95 건

8.4 미확정 항목

- 표지의 작성자·부서·승인자 인적 정보는 확인되지 않아 비워 두었다. 임의로 채우지 않는다.
- 회사/과제 지정 템플릿 경로가 지정되지 않아 **tech-doc** 기본 템플릿을 사용했다.